

MLB 자유계약선수(FA) 계약가치(AAV) 예측 모델

연구 보고서

기준 연도: 2022년 | Ridge Regression 모델

데이터: Cot's Baseball Contracts · FanGraphs · AP 팀 페이지

1. 연구 개요

MLB에서 자유계약선수(FA) 계약은 구단 운영의 핵심 의사결정이다. 잘못된 계약은 팀 재정에 수년간 악영향을 미치며, 반대로 적절한 계약은 전력 강화의 발판이 된다. 본 연구는 2002~2025년 FA 계약 데이터와 FanGraphs 세이버메트릭스 데이터를 결합하여, 선수 이름 입력만으로 AAV(연평균 계약가치)를 자동 예측하는 Ridge Regression 기반 모델을 개발한다.

2022년을 현재 시점으로 가정하고, 해당 연도 FA 선수들에 대한 예측값과 실제 계약 AAV를 비교하여 모델의 타당성을 검증한다.

2. 사용 데이터셋

2.1 데이터 출처 및 사용 이유

파일명	출처	사용 이유
MLB-Free_Agency 1991-2026.xlsx	Cot's Baseball Contracts	1991~2026년 전체 FA 계약 DB (5,598건). AAV·계약연수·계약팀·에이전트·포지션 등 계약 컨텍스트 제공. 본 모델의 예측 타겟(target)인 AAV를 포함하는 핵심 파일.
Batting.csv	FanGraphs.com (Batting Leaderboards)	2002~2025 타자 세이버메트릭스 성적 (31,982행, 47컬럼). WAR·wOBA·wRC+·ISO·BB%·K%·PA·HR·SB 등 수비독립 타격 지표 포함. 계약 직전 1~3시즌 성적 피처 구성에 사용.
Pitching.csv	FanGraphs.com (Pitching Leaderboards)	2002~2025 투수 세이버메트릭스 성적 (17,374행, 55컬럼). WAR·FIP·xFIP·SV·ERA·IP·K/9·BB/9·WHIP 등 구질·제구·결과 지표 포함. 세이브(SV) 추가 시 $R^2 +0.030$ 향상 확인.
mlb_team_payroll.csv	AP통신 / stevethump.com (수동 정리)	2002~2025년 30개 팀 오프닝데이 페이롤 (단위: 백만달러). 구단 재정력 프록시로 활용. log(payroll) 변수 추가 시 log(AAV)와 상관관계 $r=0.38$ 확인, 타자 $R^2 +0.004$ 기여.

2.2 데이터 병합 구조

4개 데이터 파일은 아래 순서로 병합된다.

- FA 계약 DB 에서 Status="signed", AAV>1,000 달러, Year≥2002 조건으로 필터링
- 선수 이름 정규화(normalize) 후 FanGraphs 데이터와 이름 기준 매칭
- 계약 직전 최대 3 시즌 성적을 lag1~lag3 피처로 변환 (WAR_lag1, FIP_lag2 등)
- 연도별 FA 시장 평균 AAV → log 변환 → 인플레이션 보정 변수(log_market_avg)
- 계약 팀 × 연도 기준으로 팀 페이롤 병합 → log_payroll 변수
- FA DB 의 에이전트 정보에서 Scott Boras 여부 → is_boras 더미 변수

최종 데이터셋: 타자 1,177건 (2002~2025) / 투수 1,271건 (2002~2025)

3. 모델 설명

3.1 알고리즘 선택: Ridge Regression

타자·투수 모두 Ridge Regression(L2 정규화 선형 모델, $\alpha=0.1$)을 최종 모델로 선택하였다. 선형 모델임에도 불구하고 비선형 모델 대비 성능 차이가 크지 않으며, 계수(β) 해석을 통해 각 피처가 AAV에 미치는 영향을 정량적으로 설명할 수 있다는 장점이 있다.

예측 방정식: $\log(AAV) = \beta_0 + \beta_1 \cdot \text{WAR_lag1} + \beta_2 \cdot \text{wOBA_lag1} + \beta_3 \cdot \log_market_avg + \dots$

예측값: $\exp(\log(AAV)) \rightarrow$ 달러 단위 AAV 출력

3.2 피처 구성

타자 피처 (최종 27 개)

피처명	설명	선택 이유
WAR_lag1~3	직전 1~3시즌 WAR	계약 시장이 가장 중시하는 종합 가치 지표
WAR_mean/max/trend	WAR 3년 평균·최대·추세	단기 성과와 커리어 피크 동시 반영
wOBA_lag1~2	직전 1~2시즌 wOBA	출루·장타를 통합한 타격 효율 지표
wRC+_lag1	직전시즌 wRC+	구장 보정 타격 생산성, 리그 평균 대비
ISO_lag1	직전시즌 ISO (SLG-AVG)	장타력 측정, HR과 중복 최소화
PA_lag1	직전시즌 타석	출장도·건강 상태 프록시
HR_lag1 / SB_lag1	홈런 / 도루	파워형 vs 발 빠른 선수 차별화
BB%_lag1 / K%_lag1	볼넷율 / 삼진율	선구안·접촉 능력
Age_at_signing	계약 시점 나이	나이 증가 $\rightarrow$ 미래 생산성 하락 반영
Season_idx	계약 연도 인덱스	연도별 연봉 인플레이션 보정
log_market_avg	FA 시장 평균 AAV (log)	해당 시즌 FA 시장 크기 반영
log_payroll	계약팀 페이롤 (log)	구단 지출 여력 $\rightarrow r=0.38$
is_boras	Boras 에이전트 여부	Boras 계약 평균 AAV는 타 에이전트의 2배
포지션 더미	C/2B/SS/MI/OF/CI/DH	포지션별 시장 공급-수요 차이 반영

투수 피처 (최종 27 개)

피처명	설명	선택 이유
WAR_lag1~3	직전 1~3시즌 WAR	투수 종합 가치, 수비 기여 포함
WAR_mean/max/trend	WAR 3년 평균·최대·추세	안정성과 피크 동시 고려
WAR_consistency	WAR 표준편차	낮을수록 안정적 $\rightarrow$ 리스크 프리미엄
FIP_lag1~2	직전 1~2시즌 FIP	수비독립 투구 성과, ERA보다 예측력 우수
ERA_lag1 / xFIP_lag1	ERA / xFIP	전통 지표 + HR 보정 실력 지표
IP_lag1	직전시즌 이닝수	건강·부상 프록시, 많을수록 가치 높음

GS_lag1	직전시즌 선발 등판수	선발투수 인증 기준
WHIP_lag1	직전시즌 WHIP	이닝당 출루 허용, 경기 지배력
SV_lag1 / SV_mean	세이브 직전/평균	클로저 프리미엄 핵심 (+R ² 0.030)
K_BB_lag1 (K/9+BB/9)	삼진-볼넷 비율	구위+제구 종합 지표
BB/9_lag1 / HR/9_lag1	볼넷율 / 피홈런율	제구·구위 세분화
is_SP	선발(1) vs 불펜(0)	선발·불펜 간 AAV 격차 구조적 차이
Age / Season_idx	나이 / 연도 인덱스	에이징 커브·인플레이션
log_market_avg / log_payroll	시장·구단 변수	성적 외 계약 맥락
is_boras	Boras 에이전트 여부	투수도 +10.5% 프리미엄 확인

4. 모델 실험

4.1 실험 설계

5-Fold Cross Validation (KFold, random_state=42)으로 모든 모델 평가. 평가 지표는 R² (결정계수). 피처 선택은 SelectKBest(f_regression, k=30) 사용. 입력 피처는 MinMaxScaler로 정규화.

4.2 알고리즘 비교 실험

동일한 피처셋에서 다양한 알고리즘을 비교하였다.

모델	타자 R ²	투수 R ²	비고
Ridge (α=0.1) ★ 최종 선택	0.764	0.644	해석 가능, 계수 직접 설명
GBM (n=500, depth=4, lr=0.02)	0.780	0.675	비선형 최고 성능
ExtraTrees (n=200, depth=10)	0.770	0.652	트리 앙상블
RandomForest (n=200, depth=10)	0.758	0.646	기본 앙상블
BayesianRidge	0.754	0.640	사전확률 기반 선형
SVR (RBF, C=10)	0.726	0.605	커널 SVM
KNN (k=10)	0.719	0.597	거리 기반
MLP (128-64-32)	0.389	0.299	데이터 부족으로 실패
Voting (GBM+RF+ET)	0.772	0.664	Soft Voting 앙상블

Ridge를 최종 선택한 이유: GBM 대비 R² 차이가 타자 0.016, 투수 0.031로 크지 않은 반면, 계수(β) 해석이 가능하여 "WAR 1단위 증가 시 AAV +X% 변화"와 같은 직관적 설명이 가능하기 때문이다.

4.3 피처 추가 실험 (투수)

투수 모델 성능 향상을 위해 단계적 피처 추가 실험을 수행하였다.

추가 변수	R ² 변화	비고
기본 성적 피처만 (WAR, FIP, IP 등)	0.598 (기준)	베이스라인
+ 세이브 SV_lag1 추가	+0.030 → 0.628	클로저 프리미엄 반영
+ ERA_lag1 추가	+0.010 → 0.638	ERA는 팬·구단 친화 지표
+ xFIP_lag1 추가	+0.008 → 0.646	HR 보정 실력 지표
+ K_BB_lag1 추가	+0.003 → 0.649	삼진-볼넷 비율
+ log_market_avg 추가	+0.005 → 0.644	인플레이션 보정
+ log_payroll 추가	+0.002 → 0.644	구단 재정력
올스타/사이영 수상 (라흐만 DB)	≈0	WAR과 중복 정보
에이전트 (is_boras)	+0.001	단독 효과 미미
팀 관중/승률 (Teams)	≈0	AAV와 무관

5. 모델 해석 (Ridge 계수 분석)

5.1 타자 모델

Ridge 계수 $\exp(\beta)-1$ 로 변환하면 해당 피처 1단위 증가 시 AAV 변화율을 나타낸다. 정규화(MinMaxScaler) 후 계수이므로 절댓값이 크면 상대적 영향력이 크다.

피처	β 계수	AAV 영향(%)	해석
wRC+_lag1	+2.11	+728%	리그 평균 대비 타격 생산성 1배↑ → AAV 7배 이상
HR_lag1	+1.20	+233%	홈런 1개 추가 시 AAV +233%
log_market_avg	+1.14	+214%	FA 시장 뜨거운 해일수록 AAV 동반 상승
WAR_mean_pre	+1.01	+175%	3년 평균 WAR 1 증가 시 +175%
log_payroll	+0.55	+73%	고페이롤 팀 영입 시 프리미엄
is_boras	+0.15	+16%	보라스 에이전트 선수 계약 프리미엄
Age_at_signing	-1.01	-64%	나이 1세 증가 시 AAV -64% (에이징 패널티)
K%_lag1	-0.64	-48%	삼진을 증가 → 접촉 능력 부족 신호
2B (포지션)	-0.23	-20%	2루수는 캐치 대비 AAV 낮음

5.2 투수 모델

피처	β 계수	AAV 영향(%)	해석
----	------------	-----------	----

WAR_mean_pre	+1.81	+513%	투수 3년 WAR 평균이 AAV의 핵심
IP_lag1	+0.85	+133%	많은 이닝 = 건강·에이스 증거
SV_mean_pre	+0.70	+101%	세이브 축적 = 클로저 프리미엄 핵심
is_SP	+0.26	+30%	선발투수 더미: 선발이 불펜보다 AAV 높음
is_boras	+0.10	+11%	보라스 에이전트 투수 소폭 프리미엄
xFIP_lag1	-2.31	-90%	xFIP 높음(=안 좋음) → AAV 크게 하락
K_BB_lag1	-2.04	-87%	K/BB 낮음(제구 불안) → 큰 패널티
WHIP_lag1	-1.48	-77%	WHIP 증가 = 경기 지배력 하락
ERA_lag1	-1.02	-64%	ERA 높음 → 팬·구단 부정적 인식
Age_at_signing	-0.56	-43%	투수도 나이 패널티 존재 (타자보다 약함)

6. 최종 성능

6.1 교차검증 성능 (5-Fold CV)

구분	CV R ²	표준편차	해석
타자 Ridge 모델	0.764	±0.025	AAV 변동의 76.4%를 성적 기반 변수로 설명
투수 Ridge 모델	0.644	±0.030	AAV 변동의 64.4%를 성적 기반 변수로 설명

투수 R²가 타자보다 낮은 이유: 같은 WAR=2.0이라도 에이스 선발(\$20M), 클로저(\$15M), 셋업맨(\$8M), 롱릴리프(\$3M)로 역할에 따라 AAV 격차가 크다. 역할(role) 정보가 is_SP 더미 하나로만 표현되어 구조적 한계가 존재한다.

7. 2022 년 FA 선수 예측 vs 실제

7.1 개요

2022년을 현재 시점으로 가정하고, 해당 연도에 FA 계약을 맺은 선수들에 대해 예측값과 실제 계약 AAV를 비교하였다. 2022년 시즌은 Corey Seager(\$32.5M), Marcus Semien(\$25M), Max Scherzer(\$43.3M) 등 대형 계약이 많았다.

오차율 = (예측 AAV - 실제 AAV) / 실제 AAV × 100%

7.2 타자 예측 결과 (상위 10 명)

선수명	포지션	실제 AAV	예측 AAV	오차율	평가
Carlos Correa	SS	\$35.1M	\$33.4M	-4.8%	✓ 우수
Nick Castellanos	RF	\$20.0M	\$21.4M	+6.8%	✓ 우수
Starling Marte	CF	\$19.5M	\$15.4M	-21.2%	△ 보통

Trevor Story	SS	\$23.3M	\$18.3M	-21.5%	△ 보통
Freddie Freeman	1B	\$27.0M	\$38.8M	+43.9%	× 과대
Kris Bryant	3B	\$26.0M	\$15.2M	-41.5%	× 과소
Kyle Schwarber	LF	\$19.8M	\$12.1M	-38.7%	× 과소
Corey Seager	SS	\$32.5M	\$22.6M	-30.6%	△ 보통
Javier Baez	SS	\$23.3M	\$15.7M	-32.8%	△ 보통
Marcus Semien	SS	\$25.0M	\$46.3M	+85.1%	× 과대

타자 평균 절대 오차: 39.4% | 중앙값 절대 오차: 26.6%

7.3 투수 예측 결과 (상위 10 명)

선수명	포지션	실제 AAV	예측 AAV	오차율	평가
Max Scherzer	SP	\$43.3M	\$49.4M	+13.9%	✓ 우수
Justin Verlander	SP	\$25.0M	\$25.7M	+2.8%	✓ 우수
Marcus Stroman	SP	\$23.7M	\$22.7M	-4.1%	✓ 우수
Robbie Ray	SP	\$23.0M	\$22.2M	-3.7%	✓ 우수
Clayton Kershaw	SP	\$17.0M	\$19.1M	+12.5%	✓ 우수
Carlos Rodon	SP	\$22.0M	\$25.3M	+15.0%	△ 보통
Kevin Gausman	SP	\$22.0M	\$29.3M	+33.2%	△ 보통
Kendall Graveman	RP	\$24.0M	\$6.2M	-74.3%	× 과소
Noah Syndergaard	SP	\$21.0M	\$4.4M	-79.2%	× 과소
Joe Kelly	RP	\$17.0M	\$4.6M	-73.0%	× 과소

투수 평균 절대 오차: 53.0% | 중앙값 절대 오차: 23.7%

7.4 오차 원인 분석

예측이 크게 벗어난 사례의 공통 원인은 다음과 같다.

- 부상 이력 미반영: Kris Bryant(작은 부상), Noah Syndergaard(Tommy John 수술 복귀)의 경우 WAR 은 정상이나 구단이 부상 리스크를 반영하여 낮게 계약. 모델에 DL/IL 정보 없음.
- 역할 변화 미반영: Kendall Graveman, Joe Kelly 등 클로저로 역할이 상승하며 시장가치 급등. SV 데이터가 1 시즌만 반영되어 역할 안착을 포착 못함.
- 시장 수요 쏠림: Marcus Semien 은 당해 SS 포지션 공급이 극히 부족하여 과열 경쟁으로 AAV 상승. 모델은 포지션 더미만 있어 공급-수요 동적 변화를 반영 불가.
- 에이징 커브 예외: Freddie Freeman 은 32 세임에도 지속적으로 상승세 유지. 모델은 선형 에이징 패널티를 적용하여 과소 추정 경향.

중앙값 오차 기준(타자 26.6%, 투수 23.7%)으로 보면 다수의 "평범한" 선수들에 대해서는 양호한 예측을 보인다. 대형 계약(top 10%)의 이상값이 평균 오차를 크게 끌어올리는 구조이다.

8. 개선 방안

순위	개선 항목	세부 내용	기대 효과
1	부상 DL/IL 데이터 추가	Baseball Reference DL 등재 일수 → 투수 리스크 변수화	투수 R^2 0.7 달성 기대
2	GBM + SHAP 도입	GBM($R^2 \approx 0.78/0.67$) + SHAP → 선수 별 기여도 시각화	성능+해석력 동시 확보
3	2002년 이전 데이터 확장	FanGraphs 1990년대 데이터 추가 → 샘플 2배+	모델 일반화 성능 향상
4	WAR 예측 파이프라인	WAR_next1~3 예측 → 평균 WAR → AAV 예측 연동	미래 기반 예측 가능
5	포스트시즌 성과 반영	Lahman PitchingPost → 가을야구 스타성 프리미엄	상위 계약 정확도 향상
6	포지션 세분화	볼펜 역할(클로저/셋업/롱릴리프) 3분류 → 더미 세분화	투수 구조적 오차 감소
7	2023~2025 검증	실제 계약 vs 예측 비교표 → 모델 타당성 대외 발표	연구 신뢰도 제고

9. 결론

본 연구는 2002~2025년 FA 계약 데이터와 FanGraphs 세이버메트릭스 데이터를 결합하여 MLB FA 선수의 AAV를 예측하는 Ridge Regression 모델을 개발하였다. 타자 $R^2=0.764$, 투수 $R^2=0.644$ 의 성능을 달성하였으며, 이는 성적 기반 변수만으로 계약 시장의 약 65~76%를 설명함을 의미한다.

2022년 FA 선수 예측에서 Max Scherzer(+13.9%), Justin Verlander(+2.8%), Carlos Correa(-4.8%) 등 주요 선수들에 대해 근접한 예측을 보였다. 다만 부상 이력이 있거나 역할 변화가 급격한 선수의 경우 오차가 크게 나타났다. 이는 수집 불가능한 정보(에이전트 협상력, 부상 세부 내역, 팀 전력 공백)에 기인한다.

Ridge 모델의 계수 분석을 통해 WAR 평균, wRC+, 세이브(클로저), 보라스 에이전트 여부 등이 AAV에 미치는 구체적 영향을 정량화하였다. 향후 부상 데이터 및 GBM+SHAP 도입 시 성능과 해석력 모두 추가 개선이 가능할 것으로 기대된다.